

RRNN - Predicción Prácticas

Por: Víctor Sánchez, Elena Gil y Juan Martínez

CUNEF Universidad – Profesor: Juan Maroñas

Dataset: Kaggle – Placement Prediction Dataset

Abstracto

Buscar prácticas como estudiante de último año puede ser estresante y está lleno de incertidumbre, todos hemos pasado por eso. Para hacer este proceso un poco más fácil, hemos creado una red neuronal que ayuda a predecir que probabilidades tiene un estudiante de ser seleccionado para unas prácticas. Analizando factores clave de los perfiles estudiantiles y de los aplicantes anteriores, nuestro modelo busca ofrecer una visión más clara sobre las posibilidades de entrar en dichas prácticas. Nuestro objetivo es crear una herramienta de apoyo que aporte algo de claridad en un momento que suele ser confuso.

Proceso iterativo hasta llegar a la solución final:

Hasta llegar a la solución final hemos probado diversas estructuras y ajustes, tanto redes Fully Connected (FCNN) como Convolucionales (CNN).

La búsqueda hacia el mejor modelo fue guiada mediante una función de coste, en nuestro caso la cross-entropía binaria, pues nuestra clase únicamente contaba con los valores “Yes” o “No”.

Además, para medir el acierto de cada modelo, usaremos el **accuracy score**

Específicamente, estas son las redes que hemos entrenado en busca del mejor modelo:

Convolucional:

- 3 convoluciones [16,32,64]
- 2 FCNN

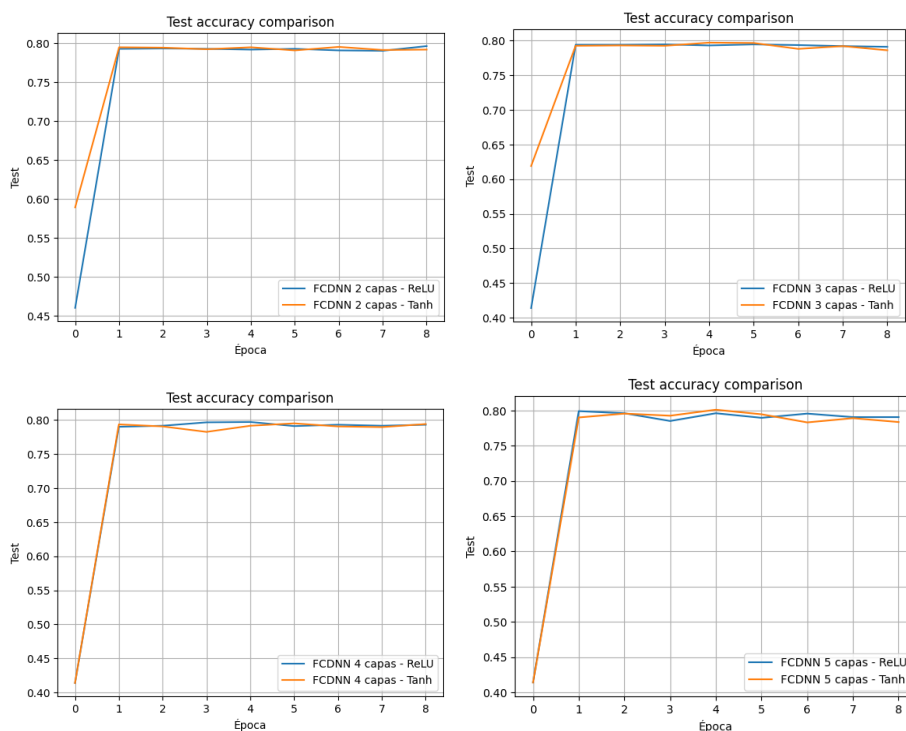
Fully Connected:

- 2 capas ocultas – ReLu
- 2 capas ocultas – Tanh
- 3 capas ocultas – ReLu
- 3 capas ocultas - Tanh
- 4 capas ocultas – ReLu
- 4 capas ocultas - Tanh
- 5 capas ocultas – ReLu
- 5 capas ocultas – Tanh

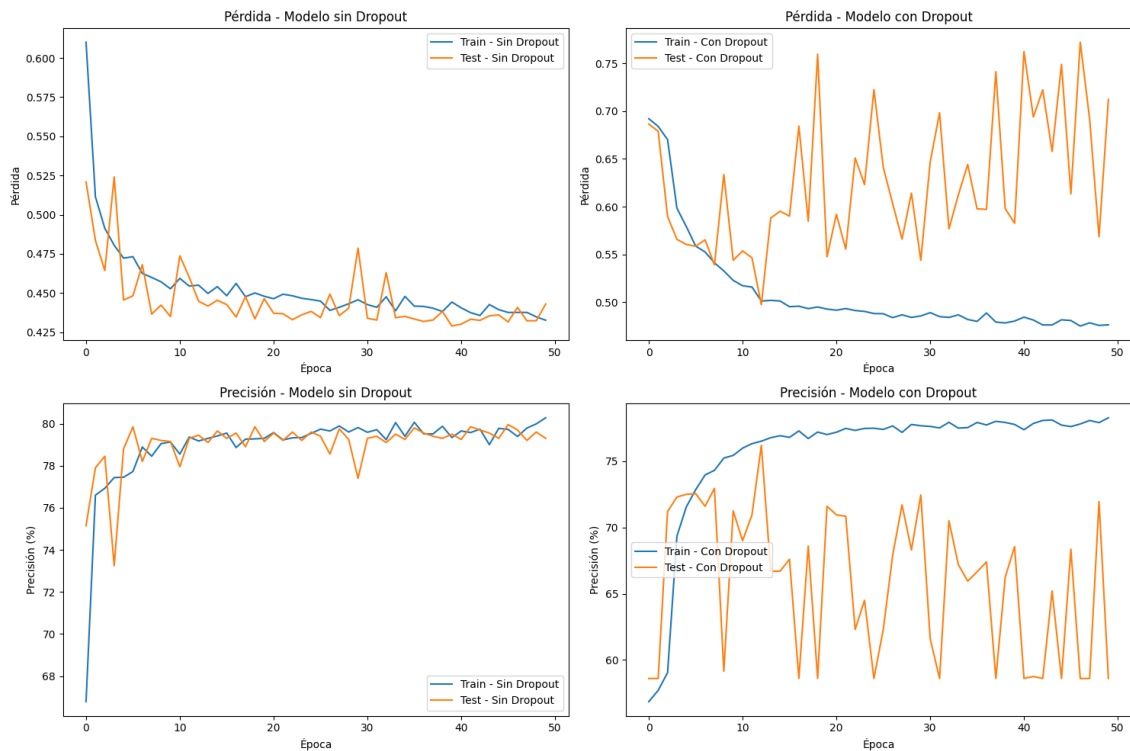
Además, sobre cada uno de estos modelos hemos aplicado mejores mediante:

Batch Normalization, Dropout, Conexiones Residuales o Learning Rate Scheduler.

Resultados Coste – FCNN – Diversas funciones de activacion



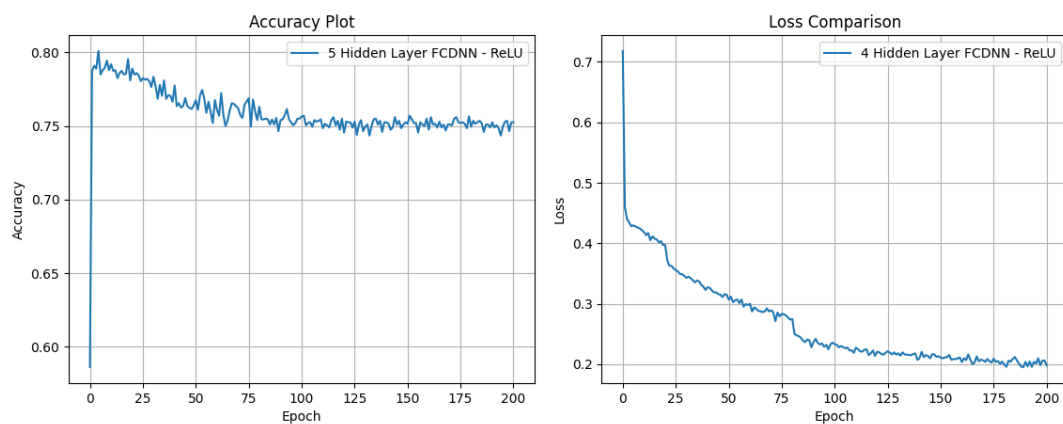
Resultados - Convolutacional



Modelo Escogido:

Finalmente nos decantamos por el modelo de red Fully Connected (FCNN), con 4 capas ocultas, función de activación ReLu. Añadiendo además Learning Rate Scheduler y Batch Normalization.

Obteniendo una precisión de 75,15%



Conclusiones:

A pesar de que el valor de precisión (75,15%) no es excesivamente alto y no esta dentro del umbral del 80% que nos habíamos marcado, este trabajo nos ha servido para visualizar el funcionamiento y entrenamiento de las redes neuronales.

En futuras versiones nos gustaría tanto mejorar el valor de precisión así como especializar y particularizar el modelo para predecir el porcentaje de entrada en compañías concretas.